<pre>Import torch import torch.nn as nn import torch.nn.functional as F import pandas as pd import matplotlibi.pyplot as plt from torch.utils.data import DataLoader, TensorDataset, random_split import seaborn as sns from sklearn.model_selection import train_test_split data = sns.load_dataset('diamonds') data.head() matricule = 2200032 #Inserer le numero/matricule de la carte d'étudiant data = sns.load_dataset('diamonds') dataframe = data.sample(220, random_state = matricule) dataframe = data.sample(220, random_state = matricule) dataframe.head()</pre> Out[29]: carat cut color clarity depth table price x y z 43712 0.51 Ideal E Sl1 61.7 55.0 1437 5.18 5.20 3.20 51787 0.74 Premium F Sl1 60.7 59.0 2415 5.85 5.82 3.54 20409 1.34 Ideal H VS2 61.9 55.0 8771 7.05 7.08 4.37
21573 1.51 Fair H VS2 57.4 61.0 9678 7.49 7.63 4.34 34801 0.31 Ideal D VS1 60.5 55.0 877 4.43 4.39 2.67 In [30]: dataFrame.describe() count 220.000000
<pre>input_cols = ["carat", "depth", "table"] categorical_cols = ["color", "clarity"] output_cols = ["price"] #extraction des données de nos variables quantitatives d'étude et matrice de corrélation: corr_matrix=dataframe[input_cols].corr() print(corr_matrix) #les coefficients de corrélations entre nos variables d'étude: print(dataframe["carat"].corr(dataframe["table"])) print(dataframe["depth"].corr(dataframe["tepth"])) print(dataframe["depth"].corr(dataframe["table"])) #diagramme présentant la matrice de corrélation: sns.heatmap(corr_matrix,annot=True, cmap='coolwarm') sns.pairplot(data-dataframe, vars=input_cols + output_cols)</pre>
Out[33]: <seaborn.axisgrid.pairgrid 0x27e5eee5910="" at=""> 1</seaborn.axisgrid.pairgrid>
E 1.5 1.0 0.5 66 64 68 68 68 68 68 68 68 68 68 68 68 68 68
In [25]: #représentation: sns.scatterplot(x="carat",y="table",data=sns.load_dataset('diamonds')) sns.sinplot(x="carat",y="table",data=sns.load_dataset('diamonds')), ci=None) plt.show()
90 - 80 - 60 - 50 - 50 - 2 carat 3 4 5
In [26]: sns.scatterplot(x="depth",y="table",data=sns.load_dataset('diamonds')) sns.lmplot(x="depth",y="table",data=sns.load_dataset('diamonds'),ci=None) plt.show()
90 - 80 - 60 - 65 70 75 80 - 65 70 75 80 - 690 - 65 70 75 80 - 65 70 70 75 80 - 65 70 70 75 80 - 65 70 70 75 80 - 65 70 70 75 80 - 65 70 70 75
In [27]: sns.scatterplot(x="carat",y="depth",data=sns.load_dataset('diamonds')) sns.lmplot(x="carat",y="depth",data=sns.load_dataset('diamonds'),ci=None) plt.show() 80
75
In [7]: dataframe1 = dataframe.copy(deep=True) sns.boxplot(x="price", data=dataframe1) echelle1=range(0,13500,1000) plt.xticks(echelle1, rotation=45) plt.show() sns.boxplot(x="carat", data=dataframe1) plt.show() sns.boxplot(x="carat", data=dataframe1) plt.show()
<pre>sns.boxplot(x="depth", data=dataframe1) plt.show() #Création d'un tableau de statistiques descriptives pour le prix: data_price=torch.tensor(dataframe1["price"]).float() mean_price=torch.mean(data_price) qp1=torch.quantile(data_price, 0.25) qp2=torch.quantile(data_price, 0.5) qp3=torch.quantile(data_price, 0.75) std_p=torch.std(data_price, 0.75) std_p=torch.std(data_price) stderr_p=std_p / torch.sqrt(torch.tensor(len(data_price))) #Intervalle de confiance pour les prix: t_value_p=torch.abs(torch.randn(len(data_price))) ci_p_lower=mean_price - t_value_p.std() * stderr_p ci_p_upper = mean_price + t_value_p.std() * stderr_p tableau_stats_price = torch.tensor([mean_price, qp1, qp2, qp3, std_p, stderr_p, ci_p_lower,ci_p_upper]) print(tableau_stats_price) #Création d'un tableau de statistiques descriptives pour le carat: data_carat=torch.tensor(dataframe1["carat"]).float() mean_carat=torch.quantile(data_carat, 0.25) qc2=torch.quantile(data_carat, 0.25) qc2=torch.quantile(data_carat, 0.75) etd_careter petitificata_carat, 0.75)</pre>
<pre>std_c=torch.std(data_carat) stderr_c=std_c / torch.sqrt(torch.tensor(len(data_carat))) #Intervalle de confiance pour carat : t_value_c=torch.abs(torch.randn(len(data_carat))) ci_c_lower=mean_carat - t_value_c.std() * stderr_c ci_c_upper = mean_carat + t_value_c.std() * stderr_c ci_c_upper = mean_carat + t_value_c.std() * stderr_c tableau_stats_carat = torch.tensor([mean_carat, qc1, qc2, qc3, std_c, stderr_c, ci_c_lower,ci_c_upper]) print(tableau_stats_carat) #Création d'un tableau de statistiques descriptives pour le depth: data_depth=torch.tensor(dataframe1["depth"]).float() mean_depth=torch.mean(data_depth) qd=torch.quantile(data_depth, 0.25) qd2=torch.quantile(data_depth, 0.5) qd3=torch.quantile(data_depth, 0.75) std_d=torch.std(data_depth, 0.75) std_d=torch.std(data_depth) stderr_d=std_d / torch.sqrt(torch.tensor(len(data_depth))) #Intervalle de confiance pour les depth : t_value_d=torch.sds(torch.randn(len(data_depth))) ci_d_lower=mean_depth - t_value_d.std() * stderr_d ci_d_upper = mean_depth + t_value_d.std() * stderr_d tableau_stats_depth = torch.tensor([mean_depth, qd1, qd2, qd3, std_d, stderr_d, ci_d_lower,ci_d_upper]) print(tableau_stats_depth)</pre>
Price price
0 1 2 3 4 5 carat 4 5
tensor([3932.7998, 950.0000, 2401.0000, 5324.2500, 3989.4397, 17.1774,
<pre>for epoch in range(100): y_pred = model(X) #calcul de la valeur prédite de y selon notre modèle linéaire loss = loss_fn(y_pred.squeeze(), Y) #calcule 1'erreur entre la valeur prédite et la valeur réelle optimizer.zero.grad() #Réinitialise les gradients de l'optimiseur à zéro. loss.backward() #calcule les gradients de la perte par rapport aux paramètres du modèle. optimizer.step() #Actualise les paramètres du modèle en utilisant les gradients calculés. if epoch % 10 == 0: #vérifie si le nombre d'itérations est multiple de 10 print(f"Epoch {epoch}, Loss {loss.item():.4f}") #retourne la valeur de epoch et le loss Epoch 0, Loss 3907.3354 Epoch 10, Loss 3526.2908 Epoch 20, Loss 3239.9746 Epoch 30, Loss 3035.6121 Epoch 50, Loss 2988.2539 Epoch 60, Loss 2982.2539 Epoch 60, Loss 2982.6328 Epoch 70, Loss 2924.7341 Epoch 80, Loss 2899.8442 Epoch 90, Loss 2879.7625 In [9]: cut_encoded = pd.get_dummies(dataframe1['cut'], prefix='cut') color_encoded = pd.get_dummies(dataframe1['color'], prefix='color')</pre>
<pre>clarity_encoded = pd.get_dummies(dataframe1['clarity'], prefix='clarity') dataframe1_encoded = pd.concat([dataframe1['clarity'], depth', 'table']], cut_encoded, color_encoded, clarity_encoded], axis=1) X = torch.tensor(dataframe1['price'].values, dtype=torch.float32) Y = torch.tensor(dataframe1['price'].values, dtype=torch.float32) print(X.shape, Y.shape) class Perceptron(nn.Module): definit(self): super(Perceptron, self)init() self.fc1=nn.Linear(23,1)#création d'une transformation linéaire qui prend input de taille 23(nombre de variables de X) et retourne un output de taille 1 def forward(self, x): x=torch.sigmoid(self.fc1(x))#application de la fonction sigmoid return x model = Perceptron() criterion=nn.MSELoss() optimizer = torch.optim.SGD(model.parameters(), lr=0.01) for epoch in range(100): optimizer = torch.optim.SGD(model.parameters()) loss = criterion(outputs, Y.unsqueeze(1)) loss.backward() optimizer.step() print("Final loss:", loss.item())</pre>
torch.Size([53940, 23]) torch.Size([53940]) Final loss: 31374384.0 In [17]: dataframe1 = dataframe.copy(deep=True) dataframe1 = pd.get_dummies(dataframe1, columns=['cut', 'color', 'clarity']) #convertit les colonnes catégorielles 'cut', 'color', et 'clarity' en variables dataframe1 = pd.get_dummies(dataframe1, std()) #standardise les données De cette manière, chaque variable a une moyenne de 0 et un écart-type o dataframe1 = dataframe1.sample(frac=1).reset_index(drop=True)#mélange les données de façon aléatoire (frac=1) et réindexe la DataFrame résultante en remettant # Séparation des données en ensembles d'entraînement et de test train_data, test_data = train_test_split(dataframe1, test_size=0.2, random_state=42) # Créer des tenseurs PyTorch à partir des données: X_train = torch.tensor(train_data.drop(['price'], axis=1).values, dtype=torch.float32) y_train = torch.tensor(train_data.drop(['price'], axis=1).values, dtype=torch.float32) X_test = torch.tensor(test_data.drop(['price'], axis=1).values, dtype=torch.float32) y_test = torch.tensor(test_data[['price'], axis=1).values, dtype=torch.float32) In [18]: # Définir la fonction de coût MSE et ses dérivées partielles : def mse_cost_function(X, y, w): predictions = torch.matmul(X,w)#Multiplication matricielle pour prédire les sorties à partir des entrées X et des poids (weights) w errors = predictions = v #l'erreur de la prédiction cost = torch.sum(errors ** 2) / (2 * len(X)#calcule la fonction de coût en utilisant la moyenne des carrés des erreurs gradients = torch.matmul(torch.transpose(X, 0, 1), errors) / len(X)#calcule le gradient du coût
<pre>gradients = torch.matmul(torch.transpose(X, 0, 1), errors) / len(X)#calcule le gradient du cout return cost, gradients # Définir la méthode de descente de gradient : def gradient_descent(X, y, learning_rate, num_iterations): # Initialiser les poids: w = torch.randn(X.shape[1], 1) # Initialiser les coûts costs = [] # Boucle de descente de gradient: for i in range(num_iterations): cost, gradients = mse_cost_function(X, y, w) w -= learning_rate * gradients costs.apend(cost) return w, costs # Tester différentes valeurs de taux d'apprentissage: #exemple1: learning_rates = [0.001] num_iterations = 1000 for j in learning_rates: weights, costs = gradient_descent(X_train, y_train, j, num_iterations) plt.plot(costs, label=str(j)) plt.ylabel('terations') plt.ylabel('terations') plt.ylabel('terations')</pre>
<pre>plt.legend() plt.show() #exemple 2: learning_rates = [0.001, 0.01, 0.1, 0.4] num_iterations = 1000 for j in learning_rates: weights, costs = gradient_descent(X_train, y_train, j, num_iterations) plt.plot(costs, label=str(j)) plt.xlabel('Iterations') plt.ylabel('Cost') plt.legend() plt.show() #exemple3: learning_rates = [0.001, 0.01, 0.1, 0.4, 0.5] num_iterations = 1000 for j in learning_rates: weights, costs = gradient_descent(X_train, y_train, j, num_iterations) plt.plot(costs, label=str(j)) plt.xlabel('Iterations') plt.ylabel('Cost') plt.legend() plt.show()</pre>
8 7 6 6 7 6 7 6 7 7 6 7 7 7 7 7 7 7 7 7
25 - 0.0
In [21]: # Définir la fonction de coût MSE et ses dérivées partielles : def mse_cost_function(X, y, w): predictions = torch.matmul(X, w)#Multiplication matricielle pour prédire les sorties à partir des entrées X et des poids (weights) w errors = predictions - y #l'erreur de la prédiction cost = torch.sum(errors ** 2) / (2 * len(X))#calcule la fonction de coût en utilisant la moyenne des carrés des erreurs gradients = torch.matmul(torch.transpose(X, 0, 1), errors) / len(X)#calcule le gradient du coût return cost, gradients #Définir la méthode de descente à pas optimal : def optimal_step_descent(X, y, num_iterations): w = torch.randn(X.shape[1], 1) costs=[] for i in range(num_iterations): alpha = torch.matmul(torch.matmul(torch.inverse(torch.matmul(torch.transpose(X, 0, 1), X)), torch.transpose(X, 0, 1)), y) cost, gradients = mse_cost_function(X, y, w) w alpha * gradients costs.append(cost)
<pre>return w, costs # Tester différentes valeurs de taux d'apprentissage: #exemple1 : learning_rates = [0.001] num_iterations = 1000 for j in learning_rates: weights, costs = gradient_descent(X_train, y_train, j, num_iterations) plt.plot(costs, label=str(j)) plt.vlabel('Iterations') plt.ylabel('Cost') plt.legend() plt.show() #exemple2 : learning_rates = [0.001, 0.01, 0.1, 0.4] num_iterations = 1000 for j in learning_rates: weights, costs = gradient_descent(X_train, y_train, j, num_iterations) plt.plot(costs, label=str(j)) plt.xlabel('Iterations') plt.ylabel('Cost') plt.legend() plt.show() #exemple3:</pre>
learning_rates = [0.001, 0.01, 0.1, 0.4, 0.5] num_iterations = 1000 for j in learning_rates: weights, costs = gradient_descent(X_train, y_train, j, num_iterations) plt.plot(costs, label=str(j)) plt.xlabel('Iterations') plt.ylabel('Cost') plt.legend() plt.show() 14 12 10 8 6 6 4
2 - 0 200 400 600 800 1000 17.5 - 0 001 001 001 001 001 001 001 001 001
In [20]: # Définir la fonction de coût MSE et ses dérivées partielles : def mse_cost_function(X, y, w): predictions = torch.matmul(X,w)#Multiplication matricelle pour prédire les sorties à partir des entrées X et des poids (weights) w errors = predictions - y #l'erreur de la prédiction cost = torch.sum(errors ** 2) / (2 * len(X))#calcule la fonction de coût en utilisant la moyenne des carrés des erreurs
<pre>gradients = torch.matmul(torch.transpose(X, 0, 1), errors) / len(X)#calcule le gradient du coût return cost, gradients #Definir la méthode de descente stochastique : def stochastic_gradient_descent(X, y, learning_rate, num_iterations): w = torch.randn(X.shape[1], 1) costs = [] for i in range(num_iterations): cost_total = 0 for j in range(len(X)): rand_index = np.random.randint(len(X)) X_j = X[rand_index].unsqueeze(0) y_j = y[rand_index].unsqueeze(0) cost, gradients = mse_cost_function(X_j, y_j, w) w = learning_rate * gradients cost_total += cost costs.append(cost_total / len(X)) return w, costs # Tester différentes valeurs de taux d'apprentissage: #exemple1 : learning_rates = [0.001] num_iterations = 1000</pre>
<pre>for j in learning_rates: weights, costs = gradient_descent(X_train, y_train, j, num_iterations) plt.plot(costs, label=str(j)) plt.xlabel('Iterations') plt.ylabel('Cost') plt.legend() plt.show() #exemple2: learning_rates = [0.001,0.01,0.1,0.4] num_iterations = 1000 for j in learning_rates: weights, costs = gradient_descent(X_train, y_train, j, num_iterations) plt.plot(costs, label=str(j)) plt.xlabel('Iterations') plt.ylabel('Cost') plt.legend() plt.show() #exemple3: learning_rates = [0.001,0.01,0.1,0.4,0.5] num_iterations = 1000 for j in learning_rates: weights, costs = gradient_descent(X_train, y_train, j, num_iterations) plt.plot(costs, label=str(j))</pre>
plt.xlabel('tcost') plt.legend() plt.show() 12 10 8 6 6 4 2 10 10 17.5 T